
Поиск объявлений услуг Авито: метод, результаты и проверка воспроизводимости

Технический отчёт по конкурсному решению
28 сентября 2026 года

Аннотация

Для каждого поискового запроса требуется вернуть не более 50 объявлений из заданного корпуса. Решение объединяет словный и символьный поиск, BM25, эмбединги multilingual-e5-small, географию и статистики обучающих взаимодействий. Две модели CatBoost отбирают итоговые объявления. На независимой локальной выборке из 1500 запросов выбранная смесь получила Recall@50, равный 0,941111. Полнота объединённого набора до отбора 50 составила 0,988667. Параметры зафиксированы до просмотра этой выборки. Мини-ноутбук применяет сохранённые модели и признаки, затем проверяет SHA256 сформированного CSV. Значение метрики на скрытом benchmark неизвестно. Источники результатов доступны в индексированном наборе доказательств [E014][E015][E016].

1. Задача и критерий качества

В условии конкурса предоставлены обучающие пары запроса и выбранного объявления, неразмеченные запросы benchmark и корпус объявлений. Для каждого запроса нужен список из не более чем 50 исходных item_id. Идентификаторы сохраняются строками, регистр и ведущие нули существенны [E001].

Пусть Q обозначает набор запросов, $R(q)$ содержит все известные релевантные объявления, а $T_{50}(q)$ содержит предсказанные 50. Целевая метрика равна

$$\text{Recall@50} = \frac{1}{|Q|} \sum_{q \in Q} \frac{|T_{50}(q) \cap R(q)|}{|R(q)|}. \quad (1)$$

Среднее берётся по запросам. Запрос с несколькими положительными объявлениями не получает больший вес. Если нужное объявление не найдено генератором

Технический отчёт по конкурсу. Использован макет ICML 2025. Документ не является публикацией ICML.

Таблица 1. Исходные данные. Числа проверяются по Parquet и профилю данных.

Файл	Число строк
train.parquet	497673
benchmark_queries.parquet	2452
benchmark_items.parquet	189212

кандидатов, оно остаётся в знаменателе и снижает итоговый Recall [E015].

2. Данные и признаки

Размеры исходных файлов приведены в таблице 1. В train наблюдаются 344825 различных объявлений. Первичный профиль даёт 73873 текста после приведения к нижнему регистру, замены ё и сведения пробелов. Полный нормализатор поиска дополнительно применяет NFKC и извлекает буквенно-числовые токены, получая 73706 текстов. Два числа относятся к разным правилам обработки [E032]. Наблюдаемая пара означает выбор пользователя, но отсутствие пары не доказывает нерелевантность объявления [E003].

Текст запроса, фильтры, заголовок, параметры и описание объявления нужны для тематического соответствия. Локация и координаты помогают отличать местные услуги от удалённых. Статистики похожих запросов дают распределение подкатегорий даже для новых объявлений. Цена, рейтинг, число отзывов и доступность связи дополняют текстовые оценки. Модель не получает идентификаторы или позицию объявления в корпусе [E027].

По первичному профилю в benchmark 37,36% текстов запросов уже встречались в train, а полный контекст встречался в 4,40% случаев. Контекст включает текст, локацию, доставку, фильтры и категорию. В train встречались только 9,59% объявлений корпуса. Последнее число относится ко всему корпусу. Доля знакомых объявлений среди скрытых правильных ответов неизвестна [E003].

Буквальное совпадение категории исключено из итого-

вых моделей. Категория поиска 0 встречается лишь в 34 строках train, но в 222 запросах benchmark. В корпусе нет объявлений категории 0. Все 34 известные положительные пары такого поиска относятся к категории 114. Смысл кода 0 не подменяется догадкой, вместо этого модель не получает нестабильный признак равенства категорий [E005].

3. Как устроен поиск

3.1. Источники кандидатов

Нормализация переводит текст в нижний регистр, заменяет букву ё на е и сохраняет числа и латиницу. Русские слова обрабатываются SnowballStemmer из NLTK [4]. Словный TF-IDF использует слова и биграммы из заголовка и параметров. Символьный TF-IDF по фрагментам длиной от 3 до 5 символов дополняет поиск при близких написаниях [3].

BM25 учитывает заголовок, параметры и первые 3000 символов описания. Заголовок повторяется трижды, параметры дважды. Используются положительный IDF, $k_1 = 1,2$ и $b = 0,65$. Дополнительный признак покрытия показывает долю разных токенов запроса, найденных в индексируемом тексте. Повторы одного слова не увеличивают эту долю [E027].

Модель multilingual-e5-small применяется локально без дообучения [1]. Запрос кодируется с фильтрами и отдельно без них. Объявление кодируется как заголовок, параметры и начало описания. Префиксы `query:` и `passage:`, усреднение токенов с учётом маски и нормализация векторов следуют карточке модели. Порядок полей и ограничения входа выбраны в этом решении.

Векторы имеют размерность 384. Для объявления используются не более 256 токенов, для запроса 128. Сохранённые векторы рассчитаны в float32 на Apple MPS пакетами по 64 текста. Ревизия модели и хеши весов зафиксированы. Проверка обнаружила конечные значения во всех массивах и максимальную ошибку единичной нормы $1,79 \cdot 10^{-7}$ [E018].

Кандидаты отбираются глобально и с географической поправкой. В объединение входят BM25, оба TF-IDF, поиск по запросу с фильтрами, обе версии E5 и выборы похожих обучающих запросов. После удаления повторов на dev остаётся в среднем 1121,07 кандидата. В benchmark среднее равно 1062,25 [E011][E034].

3.2. География и история

Совпадение локаций наблюдается в 83,10% положительных обучающих пар. У 17,41% запросов benchmark нет объявлений с тем же идентификатором локации. Поэтому расстояние используется как мягкий признак

[E004].

Центр локации оценивается по медиане координат объявлений. Для локации запроса без собственного центра используются обучающие переходы. Признаки включают расстояние, вероятность перехода и её отношение к общей частоте локации. Ширина поиска зависит от разброса наблюдаемых переходов. Правила для отдельных идентификаторов не задаются.

История похожих запросов даёт кандидатов, вероятности подкатегорий и поддержку фильтров. Первая итоговая модель также использует популярность объявления, счётчики пар с текстом и контекстом, оценку поведенческого источника и его позиции. Вторая исключает шесть прямых признаков истории объявления. Остальные агрегаты и общий набор кандидатов у моделей совпадают [E014].

3.3. Отбор 50 объявлений

Обучается `CatBoostClassifier` с функцией потерь Logloss [2]. Положительная пара получает метку 1, остальные кандидаты 0. Неполная разметка означает, что некоторые нулевые метки могут соответствовать подходящим объявлениям.

Обе модели имеют глубину 6 и скорость обучения 0,07. Модель с прямой историей содержит 700 деревьев, другая 1000. Число деревьев выбрано по Recall@50 на dev. Случайное зерно равно 42 [E014].

Перед смешиванием оценки стандартизуются внутри каждого запроса по всему набору кандидатов $C(q)$:

$$\mu_m(q) = \frac{1}{|C(q)|} \sum_{d \in C(q)} s_m(q, d), \quad (2)$$

$$\sigma_m^2(q) = \frac{1}{|C(q)|} \sum_{d \in C(q)} (s_m(q, d) - \mu_m(q))^2, \quad (3)$$

$$z_m(q, d) = \frac{s_m(q, d) - \mu_m(q)}{\sigma_m(q)}, \quad (4)$$

$$s(q, d) = 0,5z_1(q, d) + 0,5z_2(q, d). \quad (5)$$

При нулевом отклонении соответствующая оценка z_m равна нулю. При равных итоговых оценках используется исходная позиция объявления. Такой порядок фиксирует результат повторного запуска [E021][E027].

4. Проверка до отправки

4.1. Разделение и защита от утечки

Из train выбраны 6000 контекстов с 6432 положительными парами. Первые 3000 запросов используются для обучения отбора, следующие 1500 для выбора настроек и последние 1500 для независимой проверки, называе-

мой audit. Зерно разделения равно 20260928 [E006].

Проверяемые пары удалены из истории до расчёта признаков. Для новых текстов скрыты все обучающие строки с этими текстами. Дополнительно удалена история случайно выбранных 90,4% целевых объявлений. После совместного применения ограничений 96,56% положительных проверочных пар относятся к объявлениям без оставшейся истории. Такая доля служит допущением стресс-теста и не считается известным свойством скрытого benchmark [E006].

Поиск проверяется на полном корпусе benchmark с добавлением 5913 отложенных объявлений из train. Всего доступны 195125 документов. Маленькая случайная выборка негативов не используется. Тексты отложенных объявлений доступны индексам, а факты их выбора скрыты от поведенческих статистик. Повторная сборка разделения дала побайтно одинаковые четыре Parquet-файла [E007].

Независимая сверка обнаружила 22 целевых идентификатора объявлений, общих для fit с dev и audit. Поэтому части раздельны по запросам, но не полностью по объявлениям. После исключения 22 затронутых запросов остаются 1478 запросов с 1573 положительными парами. На них Recall@50 равен 0,941249, а оценка с поправкой на фильтры 0,942929. Чувствительность рассчитана без переобучения и изменения выбранной модели. Протокол приведён в report/independent_audit.json [E032].

4.2. Поправка на различие запросов

В benchmark доля запросов без фильтров равна $p = 0,6305057$. В локальной проверке она ниже. Дополнительно рассчитывается

$$R_{\text{adj}} = pR_{\text{empty}} + (1 - p)R_{\text{filtered}}. \quad (6)$$

Веса определены по открытым признакам benchmark. Поправка учитывает только наличие фильтров и не устраняет другие различия распределений [E013].

5. Результаты и ошибки

Исходный лексический поиск с географией получил Recall@50 0,858833. На том же сохранённом наборе кандидатов CatBoost повысил результат до 0,929889. Следовательно, значительная часть исходных ошибок связана с отбором 50 из уже найденных объявлений [E008][E009].

В исходном разборе 177 положительных пар находились среди кандидатов ниже 50-го места, а 53 отсутствовали в объединении. Из 53 пропусков у 26 не было словного пересечения с запросом. Для этих случа-




Рисунок 1. Развитие решения на dev. Этапы используют одну разметку, но расширенный гибридный поиск имеет другой набор кандидатов. Прибавку между этапами нельзя целиком приписать одному новому компоненту [E008][E009][E011][E013].

Таблица 2. Независимая проверка после обучения на 4500 запросах. Настройки после просмотра audit не менялись [E014][E015].

Модель	Recall@50	R_{adj}
С прямой историей	0,939778	0,941560
Без прямой истории	0,946417	0,948674
Основная смесь	0,941111	0,943178

ев добавлены два представления E5 и расширены географические словные источники. Полнота объединения на dev выросла с 0,966778 до 0,989333. Отдельного опыта, изолирующего весь вклад E5, не проводилось [E008][E011][E023].

Фильтры и вероятности подкатегорий помогают отбирать тематически близкие услуги. Покрытие полного текста добавлено потому, что нужная услуга может быть описана в теле объявления при общем заголовке. Глобальное ослабление географического штрафа ухудшало исходный Recall до 0,824389, поэтому сохранён мягкий локальный поиск с признаками ширины и переходов [E023].

На dev модель с прямой историей получила 0,942611, модель без неё 0,939167, а равная смесь 0,942944. Преимущество смеси над первой моделью составило лишь 0,000333. Парный bootstrap с 2000 повторов дал 95-процентный интервал разницы от $-0,004333$ до 0,005000. Превосходство статистически не подтверждено [E013].

Перед независимой проверкой выбранные модели переобучены на fit и dev, всего на 4500 запросах. Таб-




Рисунок 2. Recall@50 на audit и 95-процентные интервалы percentile bootstrap по запросам, 5000 повторов. Интервалы описывают разброс локальной оценки и не покрывают неизвестный сдвиг скрытого теста [E016].

лица 2 показывает результаты audit. Вариант без прямой истории оказался выше, хотя на dev был ниже. Основной ответ сохраняет заранее выбранную смесь. Для него 95-процентный bootstrap-интервал Recall@50 составляет от 0,9291 до 0,9524 [E014][E015][E016].

6. Воспроизведение и состав материалов

Мини-версия находится в папке `mini`. В ноутбук пять исполняемых ячеек: проверка файлов, загрузка кандидатов, применение моделей, отбор 50 и сохранение CSV. Для запуска нужны две модели CatBoost, списки признаков, числовая таблица кандидатов, две таблицы идентификаторов и конфигурация. Готовый CSV не используется для расчёта.

Код подготовки признаков и обучения сохранён отдельно в `reference_solution`. Для полного пересчёта нужны исходный архив конкурса и закреплённые веса E5. Применение готовых моделей в мини-версии работает без внешних API после установки зависимостей. Полная пересборка эмбеддингов на CPU вместо MPS может дать численные отличия, поэтому её побайтовая переносимость между устройствами не заявляется [E018][E020].

Проверка исходного переносимого архива подтвердила хеши 74 файлов и повторно получила три CSV. Каждый содержит 2452 запроса по 50 объявлений. Все хеши ответов совпали с конфигурациями [E020]. Новый мини-ноутбук также выполнен в отдельной папке с чистым ядром Jupyter и без готового ответа. Все пять исполняемых ячеек завершились за 5,949 секунды, а SHA256 совпал с основным ответом. Протокол хранится в `report/notebook_verification.json` [E033].

Индекс `evidence/INDEX.md` связывает документы с исходниками измерений. В `evidence/claims.csv` каждому утверждению сопоставляются источник и поле данных. Набор `data_dump` включает отчёты, результаты по отдельным запросам, конфигурации и журналы экспериментов. Для больших исходных файлов сохраняются путь, размер и SHA256. Повторная проверка доступна без переписывания методики по тексту статьи.

7. Ограничения

Выводы относятся к одной схеме разделения. Доля новых целевых объявлений в ней задана искусственно. Некоторые нулевые метки могут быть пропущенными положительными примерами. Длинные описания обрезаются, а короткие запросы иногда не позволяют восстановить причину выбора пользователя. Подбор числа деревьев и вариантов смеси по dev делает его результат оптимистичным, поэтому итоговая оценка приводится отдельно по audit.

Уровень уверенности в точности воспроизведения высокий при совпадающих артефактах и версиях библиотек. Уверенность в переносе локальной метрики на скрытый benchmark средняя. Платформа пока не предоставила оценку ответа. Запасной вариант без прямой истории сохранён для отдельного сравнения, его преимущество на скрытом тесте не предполагается.

Список литературы

- [1] Intfloat. Multilingual E5 small, model card. Закреплённая ревизия 614241f622f53c4eeff9890bdc4f31cfec418b3. <https://huggingface.co/intfloat/multilingual-e5-small>.
- [2] CatBoost. CatBoostClassifier и применение моделей. <https://catboost.ai/docs/en/concepts/python-quickstart>.
- [3] Scikit-learn. Text feature extraction, TF-IDF. https://scikit-learn.org/stable/modules/feature_extraction.html.
- [4] NLTK. Snowball stemmers. <https://www.nltk.org/api/nltk.stem.snowball.html>.